

text-TSE 实验小结

时间分辨文本线索 + Cross-Attention (Exp1) · 2026-06-16 · Libri2Mix train-clean-100, BSRNN + 冻结 MiniLM-384, 4xRTX4090D

一、背景与动机

此前三套方案（固定 13900 混音 baseline / 抗过拟合正则 / 在线动态混音）在测试集上均失败：训练集 swap gap ≈ 25 dB（机制成立），但测试集（unseen 说话人）上 oracle $\approx$ interferer ≈ 0 dB、接受率仅 3%——模型塌缩成 passthrough、无视文本。

根因诊断：旧文本线索是整句 mean-pool 成单个 384 维向量，等价于每条语句的「唯一指纹」。模型只需记住「这个向量 $\leftrightarrow$ 见过的这条声源」的查表，无需学可泛化的「内容 $\rightarrow$ 说话人」对齐 $\rightarrow$ 不迁移到 unseen。

二、本轮方法（改了什么）

- 线索表示：句向量 $\rightarrow$ 保留 MiniLM 每个 token 的 last_hidden_state (Lx384 序列，恢复时间/序列维度)。
- 融合方式：时间不变的 multiply $\rightarrow$ 在 BSRNN 子带特征上做 cross-attention（音频帧作 Query，文本 token 作 Key/Value），让模型逐帧对齐「哪个词对应哪段声学」。
- 工程：变长 token 的 padding + key_padding_mask、cue 路由、合成张量 smoke 测试（形状/掩码/文本敏感性）全部通过。

三、训练过程

不稳定 $\rightarrow$ 已解决。直接用 lr 1e-3、无 warmup 时，cross-attention 在 $\sim$ ep5 起震荡发散（train loss 冲到 0.2、始终不下负）。改为 warmup 5 epoch + lr 3e-4 + clip 1.0 后训练平滑稳定。

损失为 auraloss SISDRLoss = -SI-SDR：越负越好， ≈ 0 为 passthrough，正值比 passthrough 更差。

epoch	1	5	6	8	11	16	20	25
train	1.66	0.007	-0.020	-0.104	-0.197	-0.565	-1.02	-2.06
val	0.017	0.061	0.009	0.037	0.102	0.496	0.410	0.640

train 稳定下负（ep6 起，ep25 达 -2.06）= 训练集上学会了用文本提取；但 val 从 ~ 0.03 爆涨到 0.4-0.8，train/val 鸿沟持续拉大 = 典型过拟合。

四、评估：test swap（关键判决）

swap test：同一测试混合跑两遍——给 oracle 文本（目标转写）vs interferer 文本（干扰者转写），均以目标为参考打分。用对文本应能提取、用错文本应失败；二者差距（gap）= 模型是否真在「用文本选人」。

checkpoint	oracle SI-SDRi	oracle 接受率	interferer SI-SDRi	interferer 接受率	gap
ckpt10	-0.01	12.0%	-0.29	7.1%	+0.28 dB

ckpt15	-0.07	21.5%	-0.69	12.7%	+0.62 dB
ckpt20	-0.24	24.5%	-0.93	19.0%	+0.69 dB
baseline (句向量)	-0.03	3.2%	-0.13	—	~0.1 dB

五、结论

一句话：cross-attention 的方向是对的、能训、且比 baseline 明显更「会用文本」，但端到端只用 SI-SDR 仍训不出泛化的干净提取，会过拟合。

-  **能训**：warmup 解决了不稳定，train loss 稳定下负。
-  **更 text-aware**：测试接受率 3% → 12–24%；oracle 始终 > interferer，且 gap 随训练增大 (0.28 → 0.69 dB) ——换错文本性能稳定变差，证明模型确实在用文本选人。
-  **不泛化**：oracle 平均 SI-SDR_i ≈ 0 (unseen 说话人上即使给对文本也提不出)，与 baseline 同样的墙；同时过拟合 (train -2 / val +0.7)。

解读：时间分辨 cross-attention 比单个句向量更能抓到文本信号，但「端到端仅 SI-SDR」的监督太弱/太间接，不足以让注意力学出可泛化的「内容→说话人」对齐——模型一边变得更 text-aware、一边过拟合。

六、下一步

同任务参考工作 DAE-TSE (同样 keyword/transcript-guided TSE + BSRNN + WeSep + cross-attention, 达 16 dB SI-SDR_i / 98% 接受率) 的差异恰好指出缺口，且与本轮数据自身的指向一致：

- **音素 cue (G2P)** 替代 MiniLM 句/词向量——音素与声学直接对齐、词表有限、train/test 复现，覆盖更好。
- **给线索路径加辅助监督**：ASR(CTC) + 说话人验证 (其消融显示去掉 CTC: 16.45 → 3.47 dB) ——给 cross-attention 直接的「内容对齐 + 选人正确」梯度，这是端到端 SI-SDR 给不了的。
- **两阶段** (先训线索编码器、冻结、再训分离骨干) ——同时解决监督不足与训练不稳。

代码与脚本已提交至 fork 分支 `text-tse-wip` (commit 50d7f51)。评估脚本 `cluster/eval_swap_lr4.slurm`；训练 conf `confs/tse_bsrnn_text_xattn_lr4.yaml`。